

# Матричные разложения

обзор методов и применение в машинном обучении для понижения размерности, заполнения пропусков и рекомендаций

# Матричные разложения


$$X \approx U \cdot V^T$$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow \min$$

# SVD в линейной алгебре

- $X = U \cdot \Sigma \cdot V^T$
- $U, V$  — ортогональные,  $\Sigma$  — диагональная



# Приближение матрицы с помощью SVD

$$\underset{l \times d}{X} \approx \underset{l \times k}{U} \cdot \underset{k \times d}{V^T}$$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

$$\begin{array}{c} \overset{X}{(m \times d)} \\ \boxed{X_k} \end{array} = \begin{array}{c} \overset{\tilde{U}}{(m \times \tau)} \\ \boxed{\tilde{U}_k} \end{array} \begin{array}{c} \overset{\Sigma}{(\tau \times \tau)} \\ \boxed{\begin{array}{c|c} \Sigma_k & k \\ \hline k & \end{array}} \end{array} \begin{array}{c} \overset{\tilde{V}^T}{(\tau \times d)} \\ \boxed{\tilde{V}_k^T} \end{array} \begin{array}{c} k \\ k \end{array}$$

$k$

# Приближение матрицы с помощью SVD

$$\underset{l \times d}{X} \approx \underset{l \times k}{U} \cdot \underset{k \times d}{V^T}$$

$$\|X - U \cdot V^T\| \rightarrow \min$$

$$X = \tilde{U} \Sigma \tilde{V}^T$$

$\tilde{U}_k, \Sigma_k, \tilde{V}_k$  — усеченные матрицы из SVD

$$U = \tilde{U}_k \Sigma_k \quad V = \tilde{V}_k$$

# «SVD»

В машинном обучении

$$\underset{l \times d}{X} \approx \underset{l \times k}{U} \cdot \underset{k \times d}{V^T}$$

$$\sum_{i,j} (x_{ij} - \langle u_i, v_j \rangle)^2 \rightarrow \min$$

›  $u_i$  — “профили” объектов

›  $v_j$  — “профили” исходных признаков

# Матрица рейтингов и SVD

	<i>j</i>				<i>i</i>
	Пила	Улица Вязов	Ванильное небо	1+1	
Маша	5	4	1	2	
Юля	5	5	2		
Вова			3	5	
Коля	3	?	4	5	
Петя				4	
Ваня		5	3	3	

$$x_{ij} \approx \langle u_i, v_j \rangle$$

›  $u_i$  — "интересы пользователей"

›  $v_j$  — "параметры фильмов"

# Градиентный спуск

$$\triangleright Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

$$\frac{\partial Q}{\partial u_i} = \sum_j 2(\langle u_i, v_j \rangle - x_{ij})v_j$$

$$\triangleright \varepsilon_{ij} = (\langle u_i, v_j \rangle - x_{ij}) \text{ — ошибка на } x_{ij}$$

$$u_i^{(t+1)} = u_i^{(t)} - \gamma_t \sum_j \varepsilon_{ij} v_j$$



# SGD

GD:

$$\begin{aligned} u_i^{(t+1)} &= u_i^{(t)} - \gamma_t \sum_j \epsilon_{ij} v_j \\ v_j^{(t+1)} &= v_j^{(t)} - \eta_t \sum_i \epsilon_{ij} u_i \end{aligned}$$



SGD:

$$\begin{aligned} u_i^{(t+1)} &= u_i^{(t)} - \gamma_t \epsilon_{ij} v_j \\ v_j^{(t+1)} &= v_j^{(t)} - \eta_t \epsilon_{ij} u_i \end{aligned}$$

Для случайных  $i, j$

# Метод чередующихся наименьших квадратов (ALS)

$$Q \rightarrow \min_{u_i, v_j}$$

› Повторяем до сходимости:

$$\frac{\partial Q}{\partial u_i} = 0 \Rightarrow u_i$$

$$\frac{\partial Q}{\partial v_j} = 0 \Rightarrow v_j$$

# ALS

$$Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

$$\begin{aligned} \blacktriangleright \frac{\partial Q}{\partial u_i} &= \sum_j 2(\langle u_i, v_j \rangle - x_{i,j})v_j = 0 \\ \sum_j v_j \langle v_j, u_i \rangle &= \sum_j x_{ij}v_j \end{aligned}$$

$$\blacktriangleright \sum_j v_j v_j^T u_i = \sum_j x_{ij}v_j$$

$$\blacktriangleright \left( \sum_j v_j v_j^T \right) u_i = \sum_j x_{ij}v_j$$

# ALS

» Повторяем по случайным  $i, j$  до сходимости:

$$\left( \sum_j v_j v_j^T \right) u_i = \sum_j x_{ij} v_j \Rightarrow u_i$$

$$\left( \sum_i u_i u_i^T \right) v_j = \sum_i x_{ij} u_i \Rightarrow v_j$$

(решение системы  
линейных уравнений)

# Регуляризация

$$\triangleright Q = \sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 + \alpha \sum_i \|u_i\|^2 + \\ + \beta \sum_j \|v_j\|^2 \rightarrow \min_{u_i, v_j}$$

$\triangleright \alpha$  и  $\beta$  — небольшие положительные числа  
(0.001, 0.01, 0.5)

# Постановка задачи рекомендации

j

	Пила	Улица Вязов	Ванильное небо	1+1
Маша	5	4	1	2
Юля	5	5	2	
Вова			3	5
Коля	3	?	4	5
Петя				4
Ваня		5	3	3

i

$$x_{ij} \approx \langle u_i, v_j \rangle$$

$u_i$  — «интересы пользователей»

$v_j$  — «параметры фильмов»

# Оптимизируемый функционал

$$x_{ij} \approx \langle u_i, v_j \rangle$$

$$\sum_{i,j: x_{ij} \neq 0} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

# Оптимизируемый функционал

$$\begin{aligned} & \sum_{i,j} (\mu + b_i^u + b_j^v + \langle u_i, v_j \rangle - x_{ij})^2 + \\ & + \alpha \sum_i \|u_i\|^2 + \beta \sum_j \|v_j\|^2 + \\ & + \gamma \sum_i b_i^{u^2} + \delta \sum_j b_j^{v^2} \rightarrow \min \end{aligned}$$

- Добавили сдвиг  $\mu$ , базовые предикторы пользователя и фильма  $b$
- L2-регуляризация



# Рекомендации товаров

		<i>j</i>			
		Вечернее платье	Поднос для писем	iPhone 6s	Шуба D&G
<i>i</i>	Маша	1		1	
	Юля	1	1		1
	Вова		1	1	
	Коля	1	?	1	
	Петя		1	1	
	Ваня			1	1

$$x_{ij} = 1 \approx \langle u_i, v_j \rangle$$

$$\sum_{i,j:x_{ij} \neq 0} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

$$\Rightarrow \begin{aligned} u_i &= \frac{1}{\sqrt{d}} (1 \dots 1) \\ v_j &= \frac{1}{\sqrt{d}} (1 \dots 1) \end{aligned}$$

# Explicit и implicit

- **Explicit feedback:** есть положительные и отрицательные примеры (например, низкие и высокие оценки фильмов, лайки и дизлайки)
- **Implicit feedback:** есть только положительные (покупки, просмотры, лайки) или только отрицательные примеры (дизлайки)

# Implicit матричное разложение

$$\sum_{i,j} w_{ij} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$



Сумма по всем индексам (не только по известным элементам матрицы)

- ›  $w_{ij}$  принимает большие значения для  $x_{ij} \neq 0$  и значительно меньшие для  $x_{ij} = 0$

# Implicit ALS

$$\sum_{i,j} w_{ij} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min$$

$$w_{ij} = 1 + \alpha |x_{ij}| \quad \alpha = 10, 100, 1000$$

$u_i, v_j$  оцениваем с помощью ALS

# Вероятностный подход

$$\sum_{i,j} (\langle u_i, v_j \rangle - x_{ij})^2 \rightarrow \min_{u_i, v_j}$$

# Распределение Пуассона и матричные разложения

$$\triangleright x_{ij} \sim \text{Pois}(\langle u_i, v_j \rangle)$$

$$\triangleright P(x_{ij}) = \frac{\langle u_i, v_j \rangle^{x_{ij}}}{x_{ij}!} e^{-\langle u_i, v_j \rangle}$$

$$\triangleright \prod_{i,j} \frac{\langle u_i, v_j \rangle^{x_{ij}}}{x_{ij}!} e^{-\langle u_i, v_j \rangle} \rightarrow \max$$

$$\triangleright \sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \rightarrow \min$$

$$\triangleright \sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \rightarrow \min$$

# SGD для неотрицательного матричного разложения (NMF)

---

$$\triangleright Q = \sum_{i,j} \langle u_i, v_j \rangle - x_{ij} \ln \langle u_i, v_j \rangle \rightarrow \min$$

$$\begin{aligned} \triangleright \frac{\partial Q}{\partial u_i} &= \sum_j v_j - \frac{x_{ij}}{\langle u_i, v_j \rangle} v_j = \\ &= \sum_j \frac{\langle u_i, v_j \rangle - x_{ij}}{\underbrace{\langle u_i, v_j \rangle}_{\tilde{\epsilon}_{ij} - \text{"относительная ошибка прогноза"}}} v_j \rightarrow \min \end{aligned}$$

$$\begin{aligned} \text{SGD: } u_i^{(t+1)} &= u_i^{(t)} - \gamma_t \tilde{\epsilon}_{ij} v_j \\ v_j^{(t+1)} &= v_j^{(t)} - \eta_t \tilde{\epsilon}_{ij} u_i \end{aligned}$$

# Проблемы NMF

- Некорректно поставлена: если  $U_0, V_0$  — решение, то  $U = U_0 \cdot Y, V = V_0^T \cdot Y^{-T}$  тоже может быть решением
- $Q(X, UV^T)$  не выпукла по совокупности аргументов  $(U, V)$ , не можем использовать методы, которые находят глобальный минимум



# Блочно-покоординатные методы минимизации

- Вход:  $U_0 \geq 0, V_0 \geq 0$
- Цикл
  - $V \leftarrow f(X, U, V)$
  - $U \leftarrow g(X, U, V)$
- $f(X, U, V) = g^T(X^T, V^T, U^T)$ , поскольку задача симметрична

# NMF с нормой Фробениуса

- Оптимизационная задача:

$$\min_{U \geq 0, V \geq 0} \|X - UV^T\|_F^2 \Rightarrow (U^*, V^*)$$

- Без ограничения неотрицательности — SVD
- Базовый метод — поочерёдный градиентный спуск.

# Мультипликативные обновления

- Идея: выбрать шаги GD так, чтобы обновления стали мультипликативными

$$\frac{\partial Q}{\partial v_{jk}} = \sum_{i=1}^n u_{ik} \hat{x}_{ij} - \sum_{i=1}^n u_{ik} x_{ij}, \quad \eta_{jk} = \frac{v_{jk}}{\sum u_{ik} \hat{x}_{ij}}$$

$$v_{jk}^{(t+1)} = v_{jk}^{(t)} - \eta_{jk} \left( \sum_{i=1}^n u_{ik} \hat{x}_{ij} - \sum_{i=1}^n u_{ik} x_{ij} \right)$$

$$= v_{jk} \cdot \frac{\sum u_{ik} x_{ij}}{\sum u_{ik} \hat{x}_{ij}}$$

- В матричном виде:  $V \leftarrow V \otimes (X^T U) \oslash (\hat{X}^T U)$

# ALS и ANLS

1. На каждом шаге находится решение задачи LS по одной из компонент и проецируется на неотрицательную область.
  - Быстрый, но грубый: итерационный процесс не сходится, функция потерь осциллирует.
2. На каждом шаге точно находится покомпонентный минимум в неотрицательной области
  - Точный, но медленный.

# HALS

- На каждом шаге точно находится минимум по столбцу  $u_k$  или строке  $v_k$
- на каждом шаге небольшие вычислительные затраты
- сходится быстрее мультипликативных обновлений
- Чувствителен к начальному приближению