


# Рекуррентные нейронные сети. Часть 2.


Павел Остяков

[pavelosta@gmail.com](mailto:pavelosta@gmail.com)

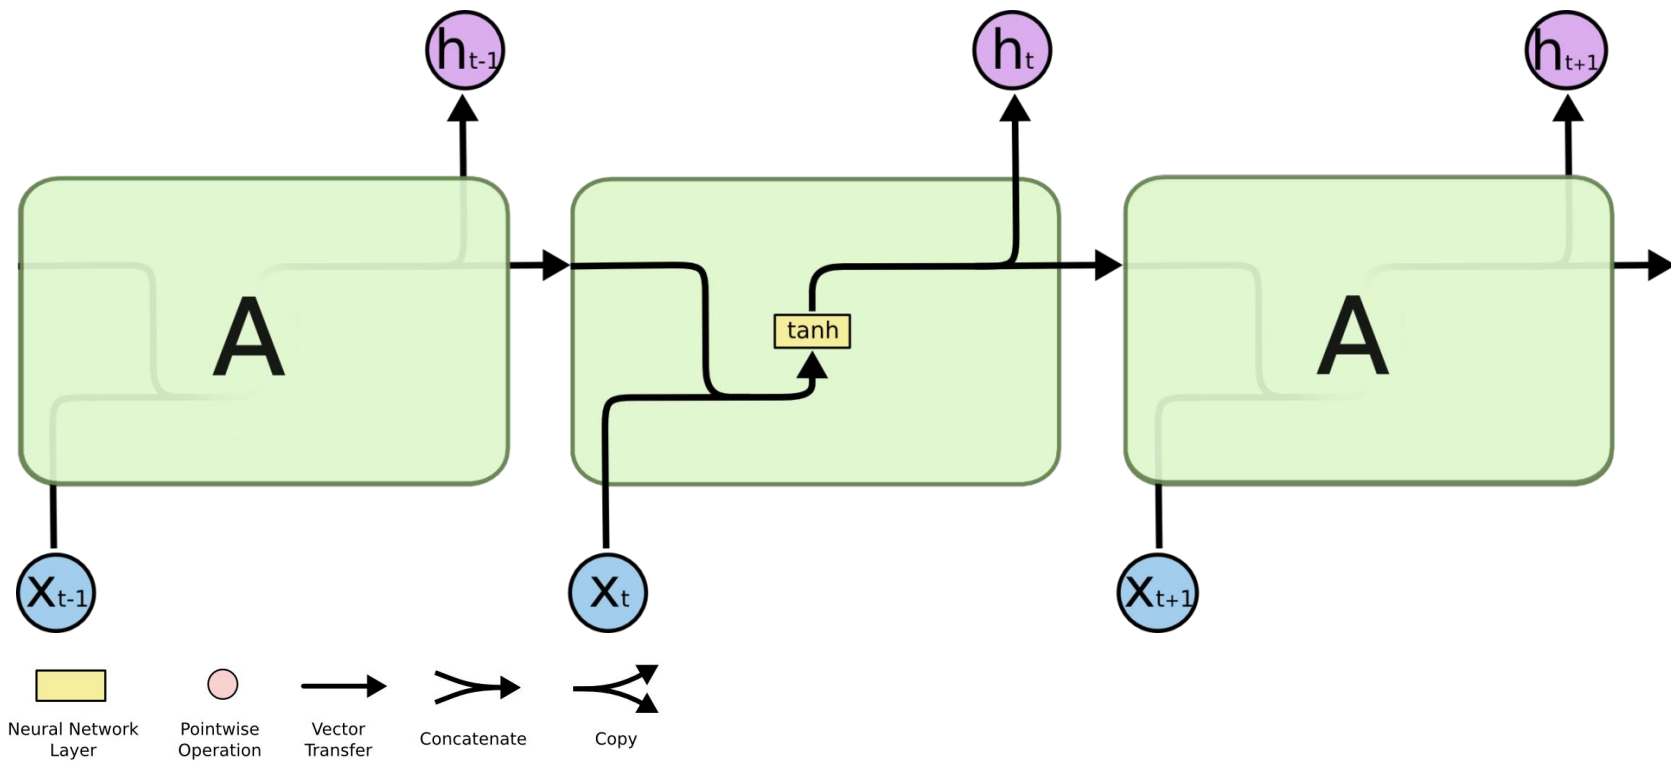
# Проблема долговременных зависимостей



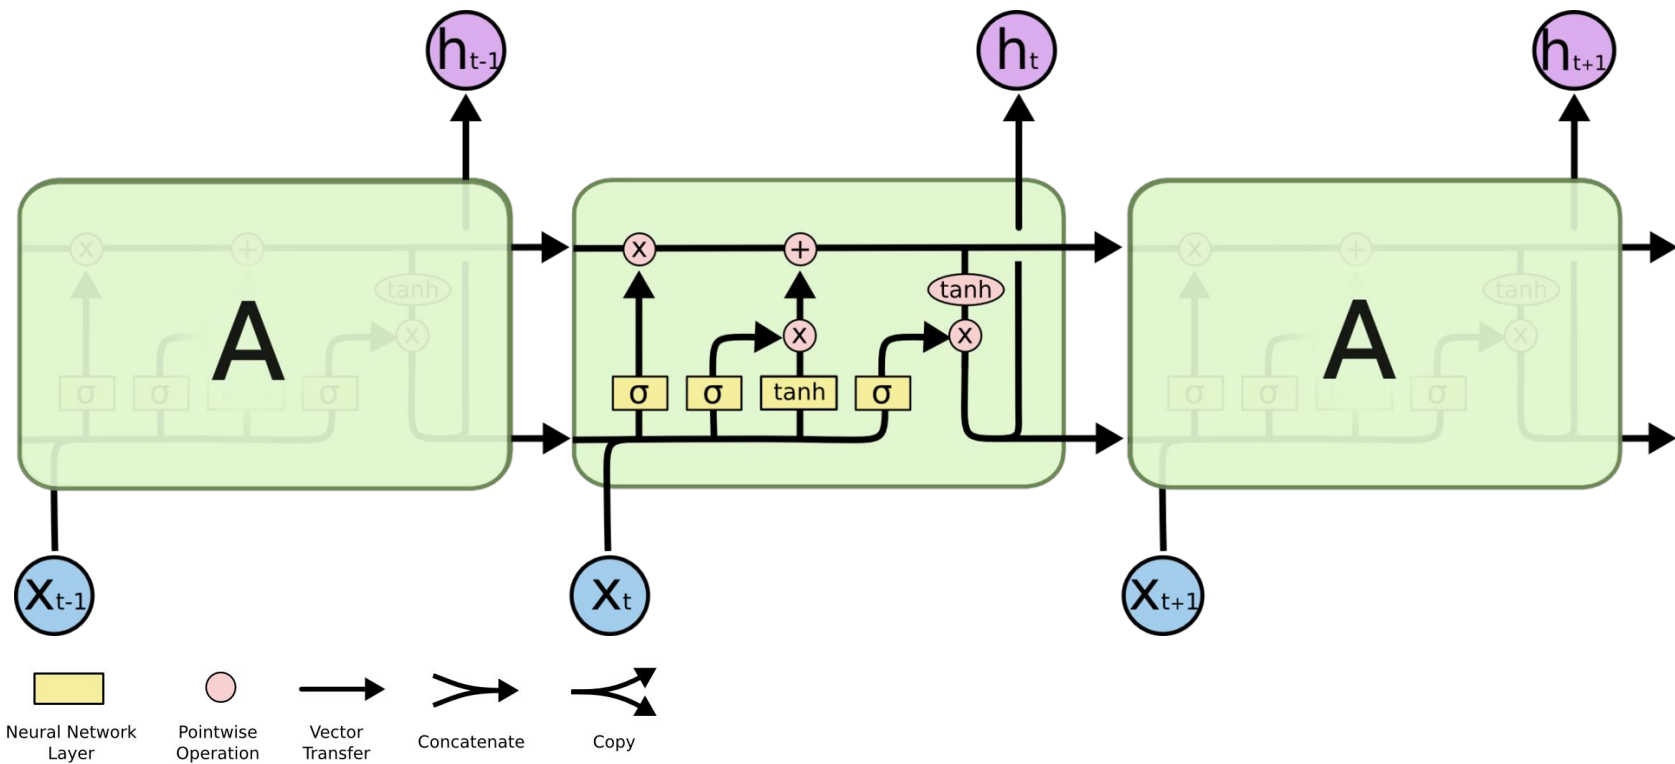
# Проблема долговременных зависимостей






# Стандартный модуль RNN




# Модуль LSTM




# Модуль LSTM. Основная идея




# Модуль LSTM. “Слой забывания”




$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$



# Модуль LSTM. Слой запоминания




$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$






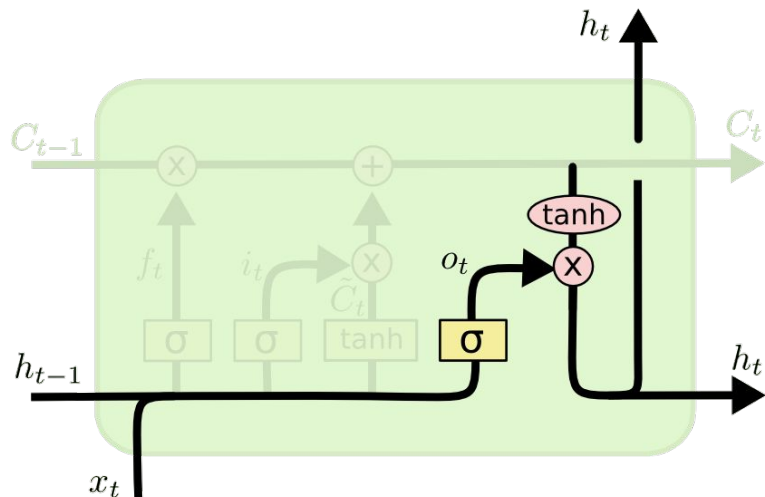
# Модуль LSTM. Обновление скрытого состояния



$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$




# Модуль LSTM. Выход ячейки




$$o_t = \sigma (W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh (C_t)$$



# Модуль LSTM



$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

$$o_t = \sigma(W_o \cdot [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

# Проблемы LSTM


- Очень медленно обучаются

```
171/2083 [=>.....] - ETA: 391648s -  
172/2083 [=>.....] - ETA: 390988s -  
173/2083 [=>.....] - ETA: 390274s -  
174/2083 [=>.....] - ETA: 389576s -  
175/2083 [=>.....] - ETA: 389055s -  
176/2083 [=>.....] - ETA: 388459s -  
177/2083 [=>.....] - ETA: 387942s -
```

- Быстро переобучаются

```
ETA: 65s - loss: 0.4846 - acc: 0.8287  
ETA: 43s - loss: 0.4845 - acc: 0.8288  
ETA: 21s - loss: 0.4843 - acc: 0.8288  
38439s - loss: 0.4842 - acc: 0.8289 - val_loss: 1.3238 - val_acc: 0.5104
```

# Модуль GRU




$$z_t = \sigma (W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma (W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh (W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$



# Модуль GRU. Особенности

- Обучаются быстрее, чем LSTM
- Меньше переобучаются
- Зачастую помогают достичь такого же (или даже лучше) качества

# Модуль SRU

$$\tilde{\mathbf{x}}_t = \mathbf{W}\mathbf{x}_t$$

$$\mathbf{f}_t = \sigma(\mathbf{W}_f\mathbf{x}_t + \mathbf{b}_f)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + (1 - \mathbf{f}_t) \odot \tilde{\mathbf{x}}_t$$

$$\mathbf{h}_t = g(\mathbf{c}_t)$$

Здесь  $g$  - некоторая функция активации

## Модуль SRU.

$$\tilde{\mathbf{x}}_t = \mathbf{W} \mathbf{x}_t$$

$$\mathbf{f}_t = \sigma(\mathbf{W}_f \mathbf{x}_t + \mathbf{b}_f)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{b}_r)$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + (1 - \mathbf{f}_t) \odot \tilde{\mathbf{x}}_t$$

$$\mathbf{h}_t = \mathbf{r}_t \odot g(\mathbf{c}_t) + (1 - \mathbf{r}_t) \odot \mathbf{x}_t$$




# SRU. Результаты

OpenNMT default setup	# layers	Size		Test BLEU	Time in RNNs
Klein et al. (2017)	2	-	-	17.60	
Klein et al. (2017) + BPE	2	-	-	19.34	
cuDNN LSTM (wd = 0)	2	85m	10m	18.04	149 min
cuDNN LSTM (wd = $10^{-5}$ )	2	85m	10m	19.99	149 min
<b>Our setup</b>					
cuDNN LSTM	2	84m	9m	19.67	46 min
cuDNN LSTM	3	88m	13m	19.85	69 min
cuDNN LSTM	5	96m	21m	20.45	115 min
SRU	3	81m	6m	18.89	12 min
SRU	5	84m	9m	19.77	20 min
SRU	6	85m	10m	20.17	24 min
SRU	10	91m	16m	20.70	40 min

Table 5: English-German translation results (Section 4.4). We list the total number of parameters and the number excluding word embeddings. Our setup disables  $\mathbf{h}_{t-1}$  input, which significantly reduces the training time. Timings are performed on a single Nvidia Titan X Pascal GPU.

# Bidirectional RNN



# Дополнительные трюки

- Сортировка батчей по длине
- Recurrent dropout
- Batch Normalization
- Data augmentation
- Residual connections

# Ссылки

- <http://colah.github.io/posts/2015-08-Understanding-LSTMs/>
- <https://arxiv.org/abs/1412.3555>
- <https://arxiv.org/pdf/1709.02755.pdf>
- <https://arxiv.org/pdf/1507.06228.pdf>
- <https://hardfish82.github.io/posts/2015-09-NN-Types-FP/>